

Prédiction des cartons jaunes

Projet de Machine Learning — apprentissage supervisé & non supervisé

FIFA World Cup 2026 — Player Performance Dataset

Kiritheepan Robinsan
ENSEA · Barcelona Summer Course 2026
Variable cible : **yellow_cards** (0 = pas de carton, 1 = carton)

Jeu de données	54 600 lignes × 75 colonnes — 1 248 joueurs — 0 valeur manquante
Modèles supervisés	Arbre de décision · Forêt aléatoire · Gradient Boosting
Interprétabilité	Importance native & permutation · SHAP (summary + waterfall)
Non supervisé	PCA · KMeans · DBSCAN
Métrique principale	F1-score (classes déséquilibrées ~90 / 10)

0. Contexte, données et préparation

L'objectif est de prédire, pour un joueur lors d'un match, s'il recevra un **carton jaune**. La cible **yellow_cards** est volontairement déséquilibrée (~90 % de 0, ~10 % de 1) : ce choix impose de raisonner en **précision / rappel / F1** plutôt qu'en simple *accuracy*, puisqu'un modèle prédisant toujours « pas de carton » atteindrait déjà ~90 % d'*accuracy* sans rien apprendre.

Exploration

Le jeu de données est propre : aucune valeur manquante et aucune valeur physiquement impossible (détection par tri sur le minimum et filtrage des colonnes négatives). La **corrélacion linéaire** de chaque variable avec la cible est quasi nulle (aucune ne dépasse ~0,04) : aucun lien simple n'existe, ce qui justifie l'emploi de modèles capables de capter des **combinaisons** de variables.

Encodage et exclusions

Les identifiants (`player_id`, `player_name`, `match_id`, `match_date`, `stadium`, `city`) et les variables à trop forte cardinalité (`nationality`, `club_name`, `team`, `opponent_team`) sont **exclus** (aucune valeur prédictive, risque de sur-apprentissage). Les variables catégorielles utiles (`position`, `preferred_foot`, `tournament_stage`, `match_result`) sont encodées en one-hot (`drop_first=True`).

Séparation train / test par joueur

Un même joueur apparaissant ~44 fois, un découpage ligne par ligne provoquerait une **fuite de données** (le même joueur des deux côtés). On sépare donc les **1 248 joueurs** en 80 % / 20 %, ce qui garantit qu'aucun joueur n'est à la fois en entraînement et en test. Résultat : **43 726** lignes d'entraînement, **10 874** de test.

1. Apprentissage supervisé

Trois modèles à base d'arbres sont entraînés puis réglés par GridSearchCV (scoring="f1"), et évalués sur le même jeu de test. Les classes déséquilibrées sont corrigées par class_weight="balanced" (forêt) et un sample_weight équilibré (boosting).

Métrique	Arbre de décision	Random Forest	Gradient Boosting
Accuracy	0,816	0,661	0,643
Précision	0,100	0,116	0,111
Rappel	0,125	0,407	0,412
F1-score	0,111	0,181	0,175
ROC-AUC	0,506	0,546	0,543

Tableau 1 — Comparaison des trois modèles sur le jeu de test (10 874 lignes, joueurs inédits).




Figure 1 — Matrices de confusion. Diagonale = bonnes prédictions ; hors-diagonale = erreurs (haut-droite = faux positifs, bas-gauche = faux négatifs).

Lecture.

L'arbre seul obtient la meilleure accuracy mais ne détecte que **125 cartons sur 1 000** (rappel 12,5 %). Le rééquilibrage des classes fait bondir le rappel de Random Forest et Gradient Boosting à ~40 %, au prix d'une accuracy plus faible et de nombreux faux positifs. Sur le critère F1, **Random Forest est légèrement le meilleur** (0,181), Gradient Boosting quasi à égalité.

Faux positifs et faux négatifs (contexte football)

Un **faux positif** = accuser à tort un joueur de risquer un carton ; un **faux négatif** = ne pas anticiper un vrai carton. Dans ce contexte, le faux positif est jugé plus coûteux (pénaliser injustement). Or Random Forest produit **~3 098 faux positifs contre 593 faux négatifs** : optimiser le F1 ne correspond donc pas à la priorité métier réelle. Un modèle orienté **précision**, ou un ajustement du seuil de décision, serait préférable pour cet usage.




Figure 2 — Courbes ROC. Les trois AUC (0,506 / 0,546 / 0,543) sont proches de 0,5 : la capacité de discrimination reste faible, même pour les meilleurs modèles.

L'amélioration du F1 obtenue par rééquilibrage traduit surtout un **déplacement du seuil de décision** (le modèle devient plus « alarmiste »), et non une meilleure capacité à distinguer les classes — ce que révèle l'AUC, qui teste tous les seuils.

2. Importance des variables & SHAP

Analyse menée sur le modèle retenu (Random Forest). L'importance native (Gini) place `jersey_number` en tête — sans aucun sens footballistique. C'est un **biais de cardinalité** bien connu : les variables à nombreuses valeurs distinctes obtiennent un score gonflé. L'**importance par permutation** le confirme : toutes les importances s'effondrent (`jersey_number` : 0,128 → 0,008). **Aucune variable n'a d'effet marquant.**




Figure 3 — SHAP summary plot. Les variables les plus cohérentes (`defensive_contribution`, `defensive_actions`) indiquent qu'un engagement défensif plus fort augmente légèrement le risque de carton. L'échelle (-0,04 à +0,03) confirme un signal global ténu.

Figure 4 — SHAP waterfall (un joueur). On part de la prédiction moyenne (0,5) pour arriver à 0,443 : bleu = pousse vers « pas de carton », rouge = vers « carton ». Ici, la forte créativité de jeu réduit le risque.

3. Apprentissage non supervisé

La cible n'est **pas** utilisée pour former les groupes ; elle sert uniquement à interpréter les résultats *a posteriori*. Les variables sont d'abord standardisées (PCA et KMeans étant sensibles à l'échelle).

PCA — réduction à 2 dimensions

Les deux premières composantes ne conservent que **30,8 %** de l'information (21,9 % + 8,9 %), attendu avec 72 variables peu corrélées. Une structure reste néanmoins visible, en partie liée au **poste** : les gardiens forment un groupe nettement séparé.




Figure 5 — Projection PCA brute (gauche) et colorée par poste (droite). Les gardiens (rose) se détachent nettement.

Clustering — KMeans vs DBSCAN

KMeans ($k = 4$) donne un **silhouette score** $\approx 0,135$ (faible) : les groupes se chevauchent et ne recouvrent pas exactement les postes. DBSCAN, appliqué sur la projection PCA ($\text{eps}=0.8$), isole **2 clusters nets** (~31 500 et 23 000 lignes) et 27 points de bruit. Le cluster isolé est **enrichi en gardiens** (18,2 % contre 6,7 %), mais le **taux de cartons y est quasi identique** (9,9 % vs 9,6 %).




Figure 6 — KMeans (gauche, 4 clusters) et DBSCAN (droite, 2 clusters + bruit) projetés sur les axes PCA.

Conclusion générale

À travers **toutes** les analyses — corrélation quasi nulle, $AUC \approx 0,5$, importances par permutation minuscules, valeurs SHAP faibles, clustering sans lien avec la cible — **aucune méthode ne parvient à prédire correctement les cartons jaunes** à partir des variables disponibles. La convergence de ces résultats en fait une conclusion solide.

C'est un résultat **cohérent et honnête** : le comportement disciplinaire dépend très probablement de facteurs **absents du dataset** (décision arbitrale, contexte instantané et tension du match) plutôt que des statistiques de jeu mesurées ici.

Sur le plan méthodologique, le projet illustre néanmoins plusieurs points essentiels :

- le **piège de l'accuracy** sur données déséquilibrées (l'arbre « bat » un modèle trivial en accuracy tout en étant inutile) ;
- le **rééquilibrage des classes** via `class_weight` et `sample_weight` ;
- l'**arbitrage précision / rappel** et son lien avec la priorité métier (coût des faux positifs) ;
- le **biais de cardinalité** des importances natives, corrigé par l'importance par permutation ;
- la différence de comportement entre **KMeans** (groupes convexes) et **DBSCAN** (densité).

Un score prédictif faible, accompagné d'une démarche rigoureuse et d'une interprétation lucide, reste un résultat de data science parfaitement valable.