

Prédiction du poste d'un joueur

Projet de Machine Learning — apprentissage supervisé & non supervisé

FIFA World Cup 2026 — Player Performance Dataset

Kiritheepan Robinsan

ENSEA · Barcelona Summer Course 2026

Variable cible : **position** — 4 classes (Défenseur · Attaquant · Gardien · Milieu)

Jeu de données	
Continuité	Même dataset et même cible que le notebook S5_P1_Fifa_Multiclasse
Modèles supervisés	Arbre de décision · Forêt aléatoire · Gradient Boosting
Interprétabilité	Importance native & permutation · SHAP (summary + waterfall)
Non supervisé	PCA · ICA · t-SNE · KMeans · DBSCAN
Métrique principale	F1 macro (4 classes, déséquilibre 3:1)
Meilleur résultat	F1 macro 0.958 · AUC 0.997 (Random Forest)

0. Contexte, données et préparation

L'objectif est de déterminer le **poste** d'un joueur (défenseur, attaquant, gardien, milieu) à partir de ses statistiques de match. L'énoncé demandant de reprendre la cible de l'expérience précédente, ce projet prolonge le notebook **S5_P1_Fifa_Multiclasse**, où la même variable était prédite par un arbre de décision, un KNN et un Naive Bayes — meilleur score alors obtenu : **89 % d'accuracy**.




Figure 1 — Répartition des 4 postes. Le rapport 3:1 entre défenseurs et gardiens justifie le F1 macro, qui traite les 4 classes à égalité.

Une fuite de données à écarter d'emblée

Avant de modéliser, il faut chercher les variables qui **trahissent trivialement** la réponse. Au football, les numéros de maillot ne sont pas attribués au hasard — et la vérification est sans appel.




Figure 2 — Les plages de numéros ne se chevauchent jamais : Gardien 1-3, Défenseur 4-12, Milieu 13-20, Attaquant 21-26.

Une seule règle sur `jersey_number` donnerait **100 % d'accuracy** sans rien apprendre du jeu. C'est une fuite au sens strict : le numéro est attribué *parce que* le joueur occupe ce poste, ce n'est pas une caractéristique de son jeu. La variable est donc **exclue**. (Le notebook S5 l'excluait déjà — bon réflexe, ici documenté et quantifié.)

En revanche, les statistiques propres aux gardiens (saves, punches, clean_sheet...), nulle pour tous les joueurs de champ, sont **conservées** : ce sont de véritables actions de match. Un modèle qui déduit « ce joueur a fait des arrêts, donc c'est un gardien » raisonne correctement.

Séparation train / test par joueur

Chaque joueur apparaît ~44 fois, et **son poste ne change jamais**. Un découpage ligne par ligne placerait le même joueur des deux côtés : le modèle mémoriserait les joueurs au lieu d'apprendre ce qui caractérise un poste. On sépare donc les **1 248 joueurs** → **43 726** lignes d'entraînement, **10 874** de test, **zéro joueur en commun** (vérifié). C'est le point que le notebook S5 ne traitait pas.

1. Apprentissage supervisé

Modèle	Meilleurs hyperparamètres	F1 macro (CV)
Arbre de décision	max_depth: None, min_samples_leaf: 5	0.926
Random Forest	max_depth: None, min_samples_leaf: 1, n_estimators: 200	0.967
Gradient Boosting	learning_rate: 0.1, max_depth: 5, n_estimators: 100	0.976

Tableau 1 — Meilleurs hyperparamètres trouvés par GridSearchCV (scoring = f1_macro, cv = 3).

Métrique	Arbre de décision	Random Forest	Gradient Boosting
Accuracy	0.914	0.958	0.958
Précision (macro)	0.918	0.961	0.960
Rappel (macro)	0.913	0.955	0.956
F1 macro	0.915	0.958	0.958
ROC-AUC (OvR)	0.960	0.997	0.997

Tableau 2 — Comparaison sur le même jeu de test (10 874 lignes, joueurs jamais vus).




Figure 3 — Les mêmes résultats en visuel.

Lecture des résultats

Random Forest et Gradient Boosting sont à égalité (0.958 de F1 macro), nettement devant l'arbre seul (0.915). L'AUC de **0,997** traduit une séparation quasi parfaite des 4 classes à tous les seuils.

Comparaison avec l'expérience précédente : le KNN du notebook S5 atteignait 89 % d'accuracy avec un split aléatoire. On obtient ici **95,8 %** avec un split *plus strict* et une fuite en moins. Le gain vient donc bien des modèles d'ensemble.




Figure 4 — Matrices de confusion des trois modèles.




Figure 5 — F1 par poste pour la Random Forest. Les quatre classes sont traitées de façon homogène (0,948 à 0,968), y compris les gardiens malgré leur effectif réduit.

Faux positifs et faux négatifs, en multiclasse

En multiclasse, chaque erreur est **à la fois** un faux négatif pour la vraie classe et un faux positif pour la classe prédite. La matrice de la Random Forest détaille lesquelles :

Confusion	Nombre	Lecture footballistique
Attaquant → Milieu	128	la frontière la plus floue
Milieu → Attaquant	111	↔ milieux offensifs et attaquants se ressemblent
Gardien → Défenseur	72	gardiens peu sollicités (0 arrêt sur le match)
Milieu → Défenseur	67	milieux défensifs
Défenseur → Milieu	50	défenseurs très portés vers l'avant

Tableau 3 — Les cinq confusions les plus fréquentes (Random Forest).

L'erreur dominante — attaquant ↔ milieu (239 cas) — a un sens réel. Un milieu offensif et un attaquant produisent des statistiques très semblables : tirs, passes clés, dribbles. Ce n'est pas un défaut du modèle, mais le reflet d'une frontière tactique réellement continue.

Le cas des gardiens est le plus instructif. Leur précision est excellente (0.979) : quand le modèle annonce « gardien », il a presque toujours raison. Mais leur rappel est plus faible (0.941) — il en rate 72. L'explication est dans les données : seuls **2 005 gardiens sur 6 300** ont au moins

un arrêt sur le match. Un gardien à 0 arrêt et 0 sortie ressemble statistiquement à un défenseur passif.

Quelle erreur est la plus grave ? Cela dépend de l'usage : pour un **recruteur** cherchant des gardiens, le rappel prime (ne pas en rater) ; pour un **étiquetage automatique** de base de données, la précision prime (ne pas polluer). Le modèle actuel favorise la précision.




Figure 6 — Courbes ROC one-vs-rest. Chaque classe est opposée à toutes les autres ; les courbes montent quasiment à l'angle supérieur gauche.

2. Importance des variables & SHAP




Figure 7 — Importance native (Gini) et importance par permutation, pour la Random Forest.

Les deux méthodes classent les variables dans le même ordre : defensive_contribution, offensive_contribution, creativity_score, puis total_goals_tournament, pass_accuracy et height_cm.

Cet accord est rassurant : lorsqu'une variable sans signification remonte en tête de l'importance native (biais de cardinalité), la permutation la fait chuter. Ici, non seulement les deux mesures concordent, mais les variables retenues ont un **sens footballistique évident** — un défenseur se définit par sa contribution défensive, un attaquant par ses buts, un milieu par sa créativité et sa précision de passe. height_cm capte les gardiens et défenseurs centraux, plus grands en moyenne. Le modèle a donc appris quelque chose de réel.




Figure 8 — SHAP summary plot pour la classe « Gardien ». Chaque point est un joueur ; rouge = valeur haute de la variable, bleu = valeur basse ; à droite = pousse vers « Gardien ». Des valeurs basses de contribution offensive et défensive (bleu à droite) poussent vers ce poste — logique, un gardien ne participe ni au pressing ni à l'attaque.




Figure 9 — SHAP waterfall pour un gardien précis. On part de la probabilité moyenne d'être gardien (~11,5 %, leur part dans les données) et on suit la construction de la prédiction, variable par variable.

3. Apprentissage non supervisé

La cible n'est **jamais** utilisée pour construire les projections ni les clusters : elle ne sert qu'à interpréter les résultats *a posteriori*.

Précaution méthodologique. La colonne position est retirée des données avant standardisation. L'oublier rendrait l'analyse circulaire : on « découvrirait » une structure liée au poste simplement parce qu'on l'aurait placée dans les variables d'entrée.




Figure 10 — Trois techniques de réduction de dimension (PCA, ICA, t-SNE), colorées par poste réel. Aucune ne fait apparaître de groupes correspondant aux postes.

Technique	Silhouette selon les postes réels
PCA (30.3 % de variance)	-0.008
ICA	+0.039
t-SNE (5 000 points)	-0.017

Tableau 4 — Ces scores sont nuls, voire négatifs : dans l'espace réduit, les postes ne se séparent pas du tout.

Le clustering confirme




Figure 11 — À gauche, les 4 clusters trouvés par KMeans ; à droite, les postes réels. Les découpes ne coïncident pas.

En attribuant à chaque cluster le poste majoritaire qu'il contient la **pureté n'atteint que 42.5 %** — à peine mieux qu'un tirage pondéré (~30 %). DBSCAN aboutit au même verdict : il isole 31 515 et 23 042 points (+ 43 de bruit) une découpe qui ne recoupe pas davantage les 4 postes.

Conclusion — la leçon principale du projet

Approche	Résultat
Prédiction supervisée du poste	F1 macro 0.958
Pureté des clusters non supervisés	42.5 %

Tableau 5 — Le contraste entre les deux parties est le vrai résultat du projet.

Comment un signal aussi fort peut-il rester invisible en non supervisé ? Parce que les deux familles de méthodes ne cherchent pas la même chose :

- **Le supervisé sait quoi chercher.** On lui fournit la réponse ; il peut donc isoler les quelques variables qui discriminent (*defensive_contribution*, *offensive_contribution*...) et les combiner finement, même si elles ne représentent qu'une faible part de la variabilité totale.
- **Le non supervisé suit la variance dominante.** PCA et KMeans se laissent guider par ce qui varie le plus parmi les 69 variables — et ici, c'est le **niveau de performance** du joueur sur le match (temps de jeu, volume d'actions), pas son poste. Le signal « poste » existe, mais il est **noyé** dans une variance plus grande.

Ce que ça enseigne : l'absence de structure visible en clustering ne signifie pas l'absence de signal exploitable. C'est l'inverse de l'intuition courante, et c'est démontré ici par deux mesures indépendantes sur un même jeu de données.

Bilan méthodologique

- détection, quantification et exclusion d'une **fuite de données** (*jersey_number*, plages disjointes par poste) ;
- séparation train/test **par joueur**, indispensable quand la cible est constante par individu ;
- choix du **F1 macro** face à un déséquilibre 3:1 entre les classes ;
- accord entre importance **native et par permutation**, validant les variables retenues ;
- **SHAP** appliqué à une classe (Gardien), globalement puis sur un joueur individuel ;
- comparaison de **trois** réductions de dimension et de **deux** algorithmes de clustering ;
- interprétation des confusions par le **sens footballistique** (frontière milieu/attaquant, gardiens peu sollicités).